

LAPORAN TEKNIS KOMPREHENSIF

ID Tim Capstone Project: CC26-PSU039

Judul Proyek : Wastefy

BAB 1: PROBLEM DISCOVERY & LOGIKA BISNIS

1. Latar Belakang Masalah

Industri katering merupakan salah satu sektor UMKM yang memiliki perputaran komoditas bahan makanan yang sangat cepat dan dinamis. Namun, di balik potensi ekonominya yang besar, industri ini menghadapi tantangan yaitu **Food Waste (Sampah Makanan)**.

Bahan makanan segar seperti buah-buahan (misalnya anggur, apel, jeruk, mangga, pisang) dan sayur-sayuran (cabai, kentang, mentimun, tomat, wortel) memiliki karakteristik biologis yang rentan terhadap pembusukan (*perishable*). Tanpa sistem pemantauan yang terukur, sisa bahan makanan seringkali menumpuk di area penyimpanan tersembunyi hingga melewati batas masa simpan optimalnya.

2. Solusi yang Ditawarkan oleh Platform Wastefy

Wastefy (Smart Waste Guard) merupakan platform manajemen inventori berbasis kecerdasan buatan yang dirancang untuk membantu catering mengurangi pemborosan makanan dan kerugian operasional. Sistem ini mengintegrasikan teknologi Computer Vision untuk mengidentifikasi kondisi fisik bahan pangan secara otomatis, model prediktif untuk memperkirakan sisa umur simpan bahan makanan, serta Generative AI yang memberikan rekomendasi tindakan dan menu pemanfaatan bahan yang mendekati masa kadaluarsa. Dengan pendekatan ini, Wastefy membantu pengelola gudang mengambil keputusan yang lebih cepat, tepat,

dan berbasis data guna meningkatkan efisiensi operasional serta meminimalkan food waste.

BAB 2: DATA ACQUISITION & EXPLORATORY DATA ANALYSIS (EDA)

1. Karakteristik Dataset Kotor (sayur_buah_kotor.csv)

A. Struktur dan Skema Dataset Kotor

Dataset kotor terdiri dari 6462 baris data dengan 6 kolom utama, namun mengandung berbagai masalah nilai kosong, format tidak konsisten, duplikasi, dan outlier.

Berikut adalah skema kolom dataset kotor:

Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai Kotor
nama_item	String	Nama buah atau sayur	NaN, N/A, ???, -
jenis_item	String	Kategori item	Null, 1, ??
lokasi_penyimpanan	String	Lokasi penyimpanan	Null, N/A, ?
hari_sejak_pembelian	Numerik / String	Hari sejak pembelian	-625.0, 1.1, 2590.0, Null
sisa_hari	Numerik / String	Perkiraan sisa umur simpan	8112.2, Null, -350.2
label	String	Kondisi item saat pangamatan	Null, N/A, 1

B. Ringkasan Masalah Kualitas Data

Kategori Masalah	Jumlah Baris Terdampak	Kolom Terdampak
Missing Vlaues (nilai	~600 baris	Semua kolom

kosong/NaN)		
Data Duplikat (baris identik)	~500 baris	Semua kolom
Outlier / Nilai Tidak Logis	~ 400 baris	Hari_sejak_pembelian, sisa_hari
Tipe Data Salah (non-numerik)	~ 300 baris	Hari_sejak_pembelian, sisa_hari

2. Proses Data Cleaning

Proses pembersihan data dilakukan secara sistematis menggunakan Python dengan library Pandas dan NumPy. Pembersihan dilaksanakan dalam lima tahap berurutan untuk memastikan setiap masalah tertangani secara tuntas sebelum melanjutkan ke tahap berikutnya.

Langkah	Proses	Teknik yang digunakan
1	Hapus Duplikat	drop_duplicates()
2	Bersihkan Nilai Kategorikal Tidak Valid	Mengisi nilai yang tidak valid dengan NaN
3	Tangani Outlier Numerik	Menentukan batasan normal untuk mengidentifikasi outlier lalu mengubahnya menjadi NaN
4	Menghapus Nilai NaN	dropna()
5	Simpan Data	to_csv()

LANGKAH 1 - Penghapusan Data Duplikat

Mengidentifikasi dan menghapus baris yang seluruh nilainya sama persis dengan baris lain. Ditemukan 1333 baris duplikat yang dihapus pada tahap ini.

```
before = len(df)
df = df.drop_duplicates()
```

```
n_dup_removed = before - len(df)
print(f"[STEP 1] Duplikat dihapus : {n_dup_removed} baris")
```

Output:

```
[STEP 1] Duplikat dihapus : 1333 baris
```

LANGKAH 2 - Bersihkan Nilai Kategorikal Tidak Valid

Kolom nama_item, jenis_item, lokasi_penyimpanan, dan label hanya boleh berisi nilai tertentu. Nilai di luar daftar yang diizinkan akan diubah menjadi NaN. Nilai tertentu sudah ditentukan sejak awal, berikut nilainya:

Kolom	Nilai Valid
nama_item	Anggur, Wortel, Pisang, Mangga, Jeruk, Apel, Kentang, Cabe, Tomat, Timun
jenis_item	Buah, Sayur
lokasi_penyimpanan	Pembeku, Pendingin, Suhu Ruang
label	Mentah, Segar, Matang, Busuk, Terlalu Matang

```
def clean_categorical(series, valid_set):
    """Set nilai di luar valid_set menjadi NaN."""
    cleaned = series.astype(str).str.strip()
    mask_invalid = ~cleaned.isin(valid_set)
    cleaned[mask_invalid] = np.nan
    return cleaned

df['nama_item'] = clean_categorical(df['nama_item'],
VALID_NAMA)
df['jenis_item'] = clean_categorical(df['jenis_item'],
VALID_JENIS)
df['lokasi_penyimpanan'] = clean_categorical(df['lokasi_penyimpanan'],
VALID_LOKASI)
```

```

df['label'] = clean_categorical(df['label'],
VALID_LABEL)

n_inval_removed =
df[['nama_item', 'jenis_item', 'lokasi_penyimpanan', 'label']].isnull().any(axis=1
).sum()
print(f"[STEP 2] Nilai kategorikal tidak valid diubah ke NaN (terdampak
{n_inval_removed} baris)")

```

Output:

```

[STEP 2] Nilai kategorikal tidak valid diubah ke NaN (terdampak 960
baris)

```

LANGKAH 3 - Tangani Outlier Numerik

Menentukan batas normal untuk mengidentifikasi nilai-nilai outlier. Nilai hari_sejak_pembelian di luar [0,30] dan sisa_hari di luar [0, 90] dianggap tidak wajar, sehingga diubah menjadi NaN.

```

df['hari_sejak_pembelian'] = pd.to_numeric(df['hari_sejak_pembelian'],
errors='coerce')
df['sisa_hari'] = pd.to_numeric(df['sisa_hari'],
errors='coerce')

mask_outlier_hari = (df['hari_sejak_pembelian'] < HARI_MIN) |
(df['hari_sejak_pembelian'] > HARI_MAX)
mask_outlier_sisa = (df['sisa_hari'] < SISA_MIN) | (df['sisa_hari']
> SISA_MAX)

n_out_hari = mask_outlier_hari.sum()
n_out_sisa = mask_outlier_sisa.sum()

df.loc[mask_outlier_hari, 'hari_sejak_pembelian'] = np.nan
df.loc[mask_outlier_sisa, 'sisa_hari'] = np.nan

print(f"[STEP 3] Outlier 'hari_sejak_pembelian' (< {HARI_MIN} atau >
{HARI_MAX}) : {n_out_hari} baris → NaN")
print(f"[STEP 3] Outlier 'sisa_hari' (< {SISA_MIN} atau > {SISA_MAX})")

```

```
: {n_out_sisa} baris → NaN")
```

Output:

```
[STEP 3] Outlier 'hari_sejak_pembelian' (< 0 atau > 30) : 497 baris  
→ NaN  
[STEP 3] Outlier 'sisa_hari' (< 0 atau > 90) : 570 baris →  
NaN
```

LANGKAH 4 - Hapus NaN

Semua baris yang masih memiliki nilai kosong (NaN) di kolom mana pun dihapus.

```
before = len(df)  
df = df.dropna()  
n_null_dropped = before - len(df)  
print(f"[STEP 4] Baris dengan nilai null dihapus : {n_null_dropped} baris")
```

Output:

```
[STEP 4] Baris dengan nilai null dihapus : 0 baris
```

LANGKAH 5 - Simpan Data

Tipe data numerik disesuaikan: hari_sejak_pembelian menjadi integer, sisa_hari dibulatkan satu desimal.

```
# Perbaiki tipe data  
df['hari_sejak_pembelian'] = df['hari_sejak_pembelian'].astype(int)  
df['sisa_hari'] = df['sisa_hari'].astype(int) # Mengubah sisa_hari  
menjadi integer  
df = df.reset_index(drop=True)  
  
# Simpan hasil  
df.to_csv(OUTPUT_PATH, index=False)  
print(f"\nHasil pembersihan disimpan ke: {OUTPUT_PATH}")
```

Output:

```
Hasil pembersihan disimpan ke: sayur_buah_bersih.csv
```

3. Karakteristik Dataset Bersih (sayur_buah_bersih.csv)


Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai
nama_item	String (kategorikal)	Nama buah atau sayur	Mangga, Timun, Apel, Wortel, Cabe, Jeruk, Anggur, Pisang, Kentang, Tomat
jenis_item	String (kategorikal)	Kategori item	Buah, Sayur
lokasi_penyimpanan	String (kategorikal)	Lokasi penyimpanan	Pembeku, Suhu Ruang, Pendingin
hari_sejak_pembelian	Numerik (integer)	Jumlah hari sejak pembelian (dibulatkan)	0, 1, 2, 3, 4, 5, 6, dst.
sisa_hari	Numerik (integer)	Perkiraan sisa umur simpan dalam hari	1, 2, 11, 30, dst.
label	String (kategorikal)	Kondisi item saat pengamatan	Matang, Busuk, Mentah, Terlalu Matang, Segar

4. Analysis Data (EDA)


Sebagai langkah awal dalam memahami karakteristik inventori bahan makanan, dilakukan Exploratory Data Analysis (EDA) untuk menggali pola dan informasi penting dari data yang tersedia. Analisis difokuskan pada empat aspek utama, yaitu komposisi dan distribusi inventori, kondisi kesegaran serta masa simpan bahan makanan, efektivitas lokasi penyimpanan, dan food waste risk analysis. Berdasarkan aspek tersebut, dirumuskan beberapa pertanyaan bisnis yang akan dijawab melalui visualisasi dan analisis data

A. Komposisi dan Distribusi Inventory


- Jenis item apa yang paling mendominasi inventori?



- Bagaimana distribusi barang berdasarkan lokasi penyimpanan?




- Berapa banyak item unik yang dikelola per kategori?




B. Analisis Masa Simpan dan Kesegaran

- Berapa rata-rata `hari\_sejak\_pembelian` untuk setiap kategori barang?




- Bagaimana distribusi label kondisi (Segar/Busuk/dll) per jenis item?




- Berdasarkan sisa_hari, berapa persentase buah yang masuk kategori Busuk, Terlalu Matang, Matang, dan Mentah?

Persentase Kategori Buah Berdasarkan Sisa Hari




C. Analisis Efektivitas Penyimpanan


- Lokasi penyimpanan mana yang paling efektif menjaga sisa umur simpan?




- Apakah ada perbedaan signifikan sisa hari antar lokasi penyimpanan?



- Bagaimana distribusi jenis item di setiap lokasi penyimpanan?




- Apakah ada kombinasi jenis item & lokasi yang tampak tidak sesuai?




D. Food Waste Risk Analysis


- Bagaimana distribusi barang persediaan berdasarkan kondisi kesehatannya (segar, mentah, matang, terlalu matang, dan busuk) menurut jenis barang?




- Kombinasi jenis item & lokasi penyimpanan mana yang paling berisiko food waste?




- Item nama mana yang memiliki rata-rata sisa hari paling rendah?



- Bagaimana tren sisa hari berdasarkan hari sejak pembelian per lokasi penyimpanan?



BAB 3: MODEL ARCHITECTURE & IMPLEMENTASI MULTI-MODEL AI



Sistem Wastefy mengintegrasikan tiga model AI yang bekerja secara berurutan dalam satu pipeline, yaitu model Computer Vision untuk klasifikasi kondisi fisik bahan makanan, model Regression untuk prediksi sisa hari umur simpan, dan Gemini AI untuk menghasilkan rekomendasi cara penyimpanan. Masing-masing model diekspos sebagai endpoint REST API yang terproteksi dan terhubung melalui gateway terpusat.

1. Computer Vision Model: Klasifikasi Kondisi Fisik

A. Arsitektur Model

Model Computer Vision menggunakan arsitektur MobileNetV2 dengan skema Transfer Learning dua fase. MobileNetV2 dipilih karena bobotnya yang ringan dan efisien, menjadikannya cocok untuk deployment pada lingkungan dengan keterbatasan sumber daya komputasi maupun perangkat mobile. Backbone MobileNetV2 terdiri dari 154 layer total dengan bobot pre-trained ImageNet.

Di atas backbone, ditambahkan classifier head yang dibangun menggunakan Keras Functional API dengan susunan sebagai berikut:

```
Inputs
MobileNetV2(training=False)
GlobalAveragePooling2D()
Dropout(0.3)
Dense(256, activation='relu')
Dropout(0.2)
Dense(30, activation='softmax')
```

Pemanggilan backbone dengan argumen training=False merupakan praktik penting agar layer BatchNorm di dalam backbone tetap berjalan dalam inference mode selama Fase 1. Tanpa ini, statistik BatchNorm akan terganggu saat backbone frozen dan menyebabkan

degradasi performa. Keputusan desain utama dirangkum pada tabel berikut:

Aspek	Keputusan	Alasan
Arsitektur	MobileNetV2 (pre-trained ImageNet)	Ringan, efisien, cocok untuk deployment mobile
Skema Training	Transfer Learning 2 Fase	Stabilisasi classifier lalu adaptasi fitur domain
Penanganan Imbalance	Undersampling + Class Weight	Menjaga keseimbangan distribusi kelas tanpa membuang terlalu banyak data
Augmentasi	On-the-fly (custom Sequence)	Hemat disk, variasi lebih besar per epoch
Out-of-Scope Filter	Confidence Threshold + Entropy	Menolak gambar di luar cakupan dataset tanpa perlu dataset negatif

B. Dataset dan Label

Dataset yang digunakan berjumlah total 68.752 gambar yang terdiri dari 30 kelas unik. Setelah proses undersampling dengan batas maksimum 1.500 gambar per kelas, total gambar yang digunakan dalam proses training adalah 24.242 gambar. Dataset mencakup 10 jenis bahan makanan: Apel, Pisang, Mangga, Jeruk, Wortel, Kentang, Cabai, Anggur, Mentimun, dan Tomat.

Struktur folder dataset mengikuti hierarki berikut:

```
sayur_buah_gambar/  
├─ buah/  
│   ├─ unripe/    ← apple_unripe/, banana_unripe/, ...  
│   ├─ ripe/  
│   ├─ overripe/  
│   └─ rotten/  
└─ sayur/  
    ├─ fresh/      ← cabe_fresh/, tomat_fresh/, ...  
    └─ rotten/
```

Format label internal model menggunakan separator || dengan pola nama_item||jenis_item||kondisi_fisik. Label kondisi fisik dibedakan berdasarkan jenis itemnya karena secara biologis tahapan kematangan buah dan sayur berbeda:

Jenis Item	Label Kondisi Fisik	Jumlah Kelas
Buah	Mentah, Matang, Terlalu Matang, Busuk	10 item × 4 kondisi = 40 kombinasi (30 aktif)
Sayur	Segar, Busuk	10 item × 2 kondisi = 20 kombinasi (20 aktif)

C. Proses Training

Training dilakukan dalam dua fase yang berurutan. Fase 1 (Feature Extraction) membekukan seluruh layer backbone sehingga hanya classifier head yang dilatih, bertujuan untuk menginisialisasi bobot classifier yang baik sebelum masuk ke tahap adaptasi fitur. Fase 2 (Fine-Tuning) melanjutkan dari checkpoint terbaik Fase 1 dengan membuka 30 layer terakhir backbone agar model dapat menyesuaikan representasi fitur domain-spesifik bahan makanan.

Parameter	Fase 1 (Feature Extraction)	Fase 2 (Fine-Tuning)
Layer yang Dilatih	Classifier head saja (backbone frozen)	Classifier head + 30 layer backbone terakhir
Learning Rate	1e-3	1e-5 (jauh lebih kecil untuk cegah catastrophic forgetting)
Max Epoch	50	30
Batch Size	32	32
Hasil Test Accuracy	91.93% (Loss: 0.2659)	93.57% (Loss: 0.1694)
Layer Backbone	154 layer (semua frozen)	154 layer (30 terakhir dibuka)

Tiga callback digunakan pada kedua fase: EarlyStopping (monitor val_loss, patience 8 epoch pada fase 1 dan 7 epoch pada fase 2), ReduceLROnPlateau (faktor 0.5, patience 3 epoch), dan ModelCheckpoint untuk menyimpan bobot terbaik secara otomatis. Augmentasi on-the-fly diterapkan meliputi horizontal flip, random crop, serta penyesuaian brightness, contrast, dan saturation.

D. Spesifikasi Endpoint API

Model Computer Vision diekspos sebagai REST API melalui FastAPI pada endpoint POST /predict/vision. Endpoint menerima file gambar bertipe JPEG atau PNG dengan ukuran maksimum 5 MB, diproteksi dengan API Key melalui header X-API-Key.

Properti	Detail
Endpoint	POST /predict/vision

Auth	Header X-API-Key
Input	Multipart form-data: file_foto (JPEG/PNG, maks. 5 MB)
Output Sukses (in-scope)	out_of_scope: false, nama_item, jenis_item, kondisi_fisik, confidence
Output Sukses (out-of-scope)	out_of_scope: true, nama_item/jenis_item/kondisi_fisik: null, confidence rendah
Error 401	API Key tidak valid atau tidak disertakan
Error 422	Format file bukan JPEG/PNG atau ukuran melebihi 5 MB
Error 500	Model gagal dimuat atau crash saat inferensi

2. Regression Model: Prediksi Sisa Hari Umur Simpan

A. Arsitektur Model

Model Regression menggunakan Feedforward Deep Neural Network (DNN) dengan arsitektur berlapis yang dirancang untuk memprediksi estimasi sisa hari ketahanan bahan makanan. Setiap layer Dense dilengkapi BatchNormalization untuk stabilisasi training, aktivasi ReLU, dan Dropout untuk mencegah overfitting. Regularisasi L2 diterapkan pada setiap layer Dense untuk meningkatkan kemampuan generalisasi.

```
Inputs
Dense(256) + L2 → BatchNorm → ReLU
Dropout(0.25)
Dense(128) + L2 → BatchNorm → ReLU
Dropout(0.25)
Dense(64) + L2 → BatchNorm → ReLU
```

```
Dense(32) → ReLU
Dense(1)
```

Loss function yang digunakan adalah Huber Loss yang lebih robust terhadap outlier dibandingkan MSE, cocok untuk data ketahanan bahan makanan yang memiliki variabilitas tinggi. Optimizer Adam dengan learning rate awal $1e-3$ dikombinasikan dengan ReduceLROnPlateau.

B. Dataset dan Label

Dataset regression bersumber dari file sayur_buah_cleaned_result.csv yang merupakan data inventori bahan makanan dengan label sisa_hari sebagai target prediksi. Model dilatih dengan 9 fitur yang mencakup fitur kategorikal, numerik, dan fitur hasil rekayasa (derived/interaction features).

No	Fitur	Tipe	Keterangan
1	nama_item	Kategorikal	Nama sayuran/buah (10 item)
2	jenis_item	Kategorikal	Sayur / Buah
3	Lokasi_ penyimpanan	Kategorikal	Suhu Ruang / Pendingin / Pembeku
4	label	Kategorikal	Busuk, Terlalu Matang, Matang, Segar, Mentah
5	Hari_sejak_ pembelian	Numerik	Dihitung dari tanggal_beli ke hari ini
6	label_score	Derived	Ordinal encoding kondisi: Busuk=0, Terlalu Matang=1, Matang=2, Segar=3, Mentah=4
7	lokasi_mult	Derived	Bobot ketahanan per lokasi:

			Suhu Ruang=1.0, Pendingin=1.8, Pembeku=3.5
8	label_x_lokasi	Interaksi	label_score × lokasi_mult
9	hari_x_lokasi	Interaksi	hari_sejak_pembelian × lokasi_mult

Fitur kategorikal di-encode menggunakan LabelEncoder, sedangkan fitur numerik dan derived dinormalisasi menggunakan RobustScaler agar tahan terhadap outlier. Dataset diaugmentasi sebanyak 3× lipat dengan menambahkan noise Gaussian ($\sigma = 0.4$) pada nilai sisa_hari untuk memperkaya distribusi training.

C. Proses Training

Training dilakukan pada dataset yang telah diaugmentasi (3× lipat dari data asli) dengan split 80% training dan 20% test menggunakan random seed yang konsisten. Validasi selama training menggunakan 10% dari data training.

Parameter	Nilai
Optimizer	Adam (lr = 1e-3)
Loss Function	Huber Loss
Max Epoch	400
Batch Size	64
Validation Split	10% dari data training
EarlyStopping	monitor val_mae, patience 30 epoch
ReduceLROnPlateau	faktor 0.5, patience 12 epoch, min_lr 1e-6

ModelCheckpoint	simpan bobot terbaik berdasarkan val_mae
-----------------	--

Setelah training, setiap prediksi melewati mekanisme safe prediction empat lapis untuk mencegah overprediksi berbahaya: (1) clip ke 0 agar tidak ada prediksi negatif, (2) upper-bound clipping berdasarkan nilai maksimum historis per kombinasi nama_item + lokasi_penyimpanan, (3) safety buffer 8% sehingga prediksi di-cap pada 92% upper bound, dan (4) pembulatan ke integer karena sisa hari tidak dapat berupa desimal.

D. Spesifikasi Endpoint API

Model Regression diekspos melalui endpoint POST /predict/regression. Request berupa JSON dengan lima field wajib. Validasi dilakukan secara komprehensif menggunakan Pydantic, termasuk validasi enum item yang didukung, format tanggal, dan nilai tanggal tidak boleh di masa depan.

Properti	Detail
Endpoint	POST /predict/regression
Auth	Header X-API-Key
Input	JSON: nama_item, jenis_item, kondisi_fisik, lokasi_penyimpanan, tanggal_beli (YYYY-MM-DD)
Output Sukses	estimasi_sisa_hari (integer, hasil safe prediction)
Error 401	API Key tidak valid atau tidak disertakan
Error 422	Item tidak terdaftar, enum tidak valid, atau tanggal di masa depan

3. Gemini AI: Rekomendasi cara simpan

A. Arsitektur dan Integrasi Model

Komponen ketiga dari pipeline Wastefy memanfaatkan Google Gemini AI sebagai Large Language Model eksternal untuk menghasilkan panduan penyimpanan yang natural dan dapat langsung dipahami pengguna. Berbeda dengan dua komponen sebelumnya yang menggunakan model yang dilatih secara lokal, komponen ini menggunakan layanan API Google AI Studio.

Model yang digunakan adalah gemini-3.5-flash dengan konfigurasi temperature = 0.2. Temperature rendah dipilih untuk menghasilkan panduan yang konsisten dan akurat, bukan respons yang kreatif atau variatif. Integrasi dilakukan melalui library google-genai dengan client yang diinisialisasi menggunakan GEMINI_API_KEY dari variabel lingkungan.

Terdapat satu penanganan kasus khusus dalam logika endpoint, apabila nilai sisa_hari bernilai 0, kondisi fisik yang dikirimkan ke prompt secara otomatis diubah menjadi "Kedaluwarsa/Perlu Segera Diolah" agar model dapat memberikan rekomendasi yang relevan untuk kondisi tersebut.

B. Prompt Engineering

Prompt template dirancang dengan struktur yang ketat untuk memastikan output yang konsisten dan dapat diparse secara programatik. Template menerima lima variabel dinamis yang merupakan kombinasi output dari model Vision dan Regression, kemudian menghasilkan respons dalam format tiga bullet points yang terstandarisasi.

Variabel dinamis dalam template:

```
{nama_item}          ← output Vision
{jenis_item}         ← output Vision
{kondisi_fisik}      ← output Vision (atau 'Kedaluwarsa' jika
sisahari = 0)
{lokasi_penyimpanan} ← input pengguna
{sisahari}           ← output Regression
```

Format output yang diwajibkan dalam prompt:

- Tindakan Prioritas: [aksi konkret yang harus segera dilakukan, maks. 12 kata]
- Cara Simpan: [instruksi penyimpanan teknis, maks. 12 kata]
- Tips Tambahan: [tips praktis menjaga kualitas bahan, maks. 12 kata]

Instruksi tambahan dalam prompt mewajibkan jawaban dalam Bahasa Indonesia, teks murni tanpa Markdown, emoji, atau kalimat tambahan di luar tiga bullet points tersebut. Pembatasan ini memastikan output dapat langsung ditampilkan ke pengguna tanpa post-processing.

C. Spesifikasi Endpoint API

Komponen GenAI diekspos melalui endpoint POST /predict/genai yang menerima input JSON berupa kombinasi hasil dari kedua model sebelumnya ditambah informasi lokasi penyimpanan. Validasi Pydantic diterapkan untuk seluruh field input.

Properti	Detail
Endpoint	POST /predict/genai
Auth	Header X-API-Key
Input	JSON: nama_item, jenis_item,

	kondisi_fisik, lokasi_penyimpanan, sisa_hari (integer 0–40)
Output Sukses	cara_simpan (string 3 bullet points panduan penyimpanan)
Error 401	API Key tidak valid atau tidak disertakan
Error 422	Nilai input di luar enum yang valid atau sisa_hari di luar range 0–40
Error 500	Gagal terhubung ke Gemini API

Alur integrasi ketiga model dalam satu pipeline:

Urutan	Model	Input	Output
1	Vision (MobileNetV2)	File gambar JPEG/PNG	nama_item, jenis_item, kondisi_fisik, confidence
2	Regression (DNN)	nama_item, jenis_item, kondisi_fisik, lokasi_penyimpanan, tanggal_beli	sisa_hari
3	Gemini AI	nama_item, jenis_item, kondisi_fisik, lokasi_penyimpanan, sisa_hari	cara_simpan

BAB 4: EVALUASI PERFORMA & ANALISIS INTEGRASI

- 1. Metrik Evaluasi, Imbalance Dataset, dan Penanganan Out of Scope

Evaluasi sistem Wastefy dilakukan pada tiga dimensi utama: metrik performa kuantitatif dari setiap model, analisis penanganan ketidakseimbangan dataset, dan mekanisme penolakan input di luar cakupan sistem (out-of-scope handling).

A. Metrik Evaluasi

- Vision Model

Evaluasi model Computer Vision dilakukan menggunakan metrik klasifikasi standar pada test set yang sepenuhnya dipisahkan dari data training dan validasi. Test set dibentuk dengan stratified split sebesar 15% dari total dataset untuk memastikan distribusi kelas yang proporsional.

Metrik	Fase 1 (Feature Extraction)	Fase 2 (Fine-Tuning)
Test Accuracy	91.93% (Loss: 0.2659)	93.57% (Loss: 0.1694, +1.64%)
Loss Function	Categorical Cross-Entropy	Categorical Cross-Entropy
Evaluasi per Kelas	Classification Report (Precision, Recall, F1)	Classification Report + perbandingan delta vs Fase 1
Visualisasi	Confusion Matrix, Accuracy Heatmap per item	Confusion Matrix, F1 comparison chart

Analisis per kelas mengidentifikasi tiga kelas dengan F1-score paling rendah. Tabel berikut membandingkan hasil Fase 1 dan Fase 2:

Kelas	F1 Fase 1	F1 Fase 2	Keterangan
Mangga_Terlalu Matang	0.50	0.40 (turun)	Precision turun (0.30), recall naik (0.59). Sampel sangat terbatas (support=17), batas visual gradual.
Anggur_Matang	0.58	0.68 (naik)	Meningkat. Variasi warna anggur antar varietas masih jadi tantangan.
Jeruk_Terlalu Matang	0.72	0.77 (naik)	Meningkat. Perubahan warna kulit jeruk tidak konsisten antar sampel.

- Regression Model

Evaluasi model Regression menggunakan dua metrik utama yang umum digunakan pada masalah regresi kontinu. Prediksi dievaluasi dalam dua versi: prediksi raw (sebelum safe prediction) dan prediksi safe (setelah mekanisme clipping diterapkan).

Metrik	Nilai	Keterangan
MAE (raw, test set)	~2.28 hari	Mean Absolute Error sebelum safe prediction
MAE (safe prediction)	~2.30 hari	Mean Absolute Error setelah mekanisme clipping (+0.02 hari)
RMSE	~3.36 hari	Root Mean Square Error, lebih sensitif terhadap error besar
Noise Floor Dataset	~2.50 hari	Standar deviasi within-group (batas teoritis MAE yang dapat dicapai)

MAE sebesar ~ 2.28 hari mendekati noise floor estimasi dataset (~ 2.50 hari), mengindikasikan model telah mencapai batas kemampuan yang realistis mengingat variabilitas inherent data ketahanan bahan makanan. Selisih MAE antara prediksi raw dan safe yang sangat kecil (~ 0.02 hari) menunjukkan mekanisme safety clipping tidak mengorbankan akurasi secara signifikan.

B. Imbalance Dataset

- Vision Model

Dataset Computer Vision memiliki dua sumber ketidakseimbangan yang bersifat struktural. Pertama, ketidakseimbangan antar jenis item karena perbedaan jumlah sampel gambar per item yang tersedia di dataset asli. Kedua, ketidakseimbangan antar kondisi karena buah memiliki 4 label kondisi sementara sayur hanya 2 label, sehingga secara agregat kelas-kelas buah memiliki lebih banyak variasi.

Strategi penanganan yang diterapkan secara kombinatif. Pertama, Undersampling dengan batas (cap) 1.500 gambar per kelas. Total dataset berkurang dari 68.752 menjadi 24.242 gambar, namun distribusi antar kelas menjadi jauh lebih seimbang. Kedua, Class Weight berbasis sklearn `compute_class_weight` dengan mode 'balanced', sehingga kelas dengan sampel lebih sedikit mendapat bobot loss yang lebih besar selama training dan model tidak bias ke kelas mayoritas. Ketiga, Augmentasi on-the-fly yang diterapkan secara merata

pada setiap kelas meliputi horizontal flip, random crop, serta penyesuaian brightness, contrast, dan saturation.

- Regression Model

Dataset regression memiliki ketidakseimbangan distribusi pada nilai sisa_hari yang disebabkan oleh dua faktor. Pertama, distribusi kondisi yang tidak merata: kondisi Busuk secara alami memiliki sisa hari mendekati 0, sementara kondisi Mentah atau Segar memiliki sisa hari jauh lebih tinggi. Kedua, efek lokasi penyimpanan yang memperbesar rentang distribusi karena item di Pembeku dapat bertahan hingga beberapa kali lipat dibanding Suhu Ruang.

Analisis noise floor menunjukkan standar deviasi within-group (kelompok dengan nama_item, lokasi_penyimpanan, dan label identik) rata-rata ~2.50 hari, yang menjadi batas teoritis MAE minimum yang dapat dicapai model.

Strategi penanganan yang diterapkan. Pertama, augmentasi data 3× lipat dengan noise Gaussian ($\sigma = 0.4$) pada nilai sisa_hari untuk memperkaya distribusi training dan mengurangi overfitting pada nilai sisa hari yang jarang muncul. Kedua, RobustScaler untuk normalisasi fitur numerik, yang menggunakan median dan IQR sebagai parameter skalasi sehingga lebih tahan terhadap outlier dibanding StandardScaler. Ketiga, fitur interaksi label_x_lokasi dan hari_x_lokasi membantu model memahami bahwa dampak

kondisi fisik terhadap sisa hari bersifat relatif terhadap lokasi penyimpanan, bukan absolut.

C. Penanganan Out-of-Scope

- Vision Model

Tantangan utama deployment model klasifikasi tertutup adalah penanganan input yang berada di luar cakupan training. Karena arsitektur softmax selalu menghasilkan distribusi probabilitas yang berjumlah 1, model berpotensi memberikan prediksi yang terlihat meyakinkan meskipun inputnya sama sekali bukan buah atau sayur.

Sistem mengimplementasikan dua mekanisme filter yang diterapkan secara bersamaan (logika OR, cukup satu kondisi terpenuhi untuk menolak):

Mekanisme	Nilai Threshold	Logika
Confidence Threshold	0.70	Ditolak jika $\max(\text{softmax}) < \text{threshold}$. Gambar in-scope menghasilkan distribusi yang menukik tajam pada satu kelas.
Entropy Threshold	0.75	Ditolak jika entropi Shannon terlalu tinggi. Gambar out-of-scope membagi probabilitas ke banyak kelas karena tidak ada yang cocok, mendekati nilai maksimum $\log(30) \approx 3.40$.

Threshold ditentukan secara data-driven berdasarkan distribusi confidence dan entropy pada test set in-scope, P5 dari

distribusi confidence sebagai batas bawah, dan P99 dari distribusi entropy sebagai batas atas. Nilai-nilai ini disimpan di model_metadata.json dan dibaca otomatis saat startup sehingga dapat disesuaikan tanpa mengubah kode aplikasi.

- Regression Model

Pada model Regression, out-of-scope handling bersifat deterministik dan ditangani pada lapisan validasi input sebelum data sampai ke model. Terdapat tiga lapisan validasi yang diterapkan secara berurutan. Pertama, validasi enum nama_item, hanya 10 item yang didukung (Anggur, Apel, Cabai, Jeruk, Kentang, Mangga, Mentimun, Pisang, Tomat, Wortel). Item di luar daftar ini ditolak dengan HTTP 422. Kedua, validasi enum kondisi_fisik dan lokasi_penyimpanan, memastikan nilai yang dikirim sesuai dengan kelas yang dikenal model. Input dengan nilai di luar enum akan menyebabkan LabelEncoder gagal melakukan transformasi. Ketiga, validasi range tanggal_beli, tanggal tidak boleh di masa depan karena hari_sejak_pembelian yang negatif tidak memiliki makna bisnis dan berada di luar distribusi data training.

Di sisi output, mekanisme safe prediction juga berfungsi sebagai out-of-scope guard, prediksi yang melebihi upper bound historis untuk kombinasi item dan lokasi tertentu dianggap tidak realistis dan secara otomatis di-clip ke nilai maksimum yang pernah diamati dalam data training (0 - 40).

- Gemini AI

Komponen Gemini AI menerapkan validasi enum yang ketat pada semua field input melalui Pydantic field_validator. Validasi ini memastikan hanya kombinasi nilai yang bermakna secara domain yang diteruskan ke Gemini API, sehingga model tidak diminta menghasilkan panduan untuk bahan makanan atau kondisi yang tidak dikenal sistem.

Field	Validasi Out-of-Scope	Response jika Ditolak
nama_item	Harus salah satu dari 10 item yang terdaftar	HTTP 422 dengan pesan daftar item valid
jenis_item	Harus 'Buah' atau 'Sayur'	HTTP 422
kondisi_fisik	Harus salah satu dari 5 kondisi valid	HTTP 422
lokasi_penyimpanan	Harus salah satu dari 3 lokasi valid	HTTP 422
sisa_hari	Integer dalam range 0–40 hari	HTTP 422 (ge=0, le=40 constraint Pydantic)

2. Arsitektur Integrasi Sistem (Express.js Gateway ke Hugging Face FastAPI)

Backend Wastefy dibangun menggunakan Express.js yang berperan sebagai API gateway antara aplikasi mobile frontend dan layanan AI eksternal. Semua request dari frontend masuk melalui backend terlebih dahulu, sehingga API key dan kredensial sensitif tidak pernah terekspos ke sisi client.

Layanan AI Wastefy di-host di Hugging Face Spaces menggunakan FastAPI sebagai framework Python-nya, dan menyediakan tiga endpoint utama: /predict/vision untuk klasifikasi kondisi fisik buah dan sayur dari gambar, /predict/regression untuk estimasi sisa hari simpan berdasarkan data item, dan /predict/genai untuk menghasilkan panduan penyimpanan menggunakan Gemini AI.

Setiap request dari Express.js ke AI service diautentikasi menggunakan header X-API-Key. Backend memvalidasi input terlebih dahulu sebelum meneruskan request, termasuk pengecekan format file gambar, ukuran maksimal 5MB, dan validasi daftar item yang didukung. Untuk kondisi busuk, backend melakukan bypass langsung tanpa memanggil model AI, sehingga mengurangi beban request yang tidak perlu ke AI service.

Response dari AI service kemudian diproses oleh backend. Termasuk pemetaan field, pembatasan nilai sisa_hari antara 0 hingga 40, dan penentuan status kesegaran (Fresh, Soon, Expired), sebelum dikembalikan ke frontend dalam format response yang sudah diseragamkan.

BAB 5: KESIMPULAN DAN REKOMENDASI PENGEMBANGAN